



Національний технічний університет України
«Київський політехнічний інститут імені Ігоря Сікорського»
Науково-навчальний фізико-технічний інститут
Кафедра інформаційної безпеки

Комп'ютерний практикум №1

з дисципліни «Криптографія»

Мета: Засвоєння понять ентропії на символ джерела та його надлишковості, вивчення та порівняння різних моделей джерела відкритого тексту для наближеного визначення ентропії, набуття практичних навичок щодо оцінки ентропії на символ джерела.

Виконали:

Студенти групи ФБ-43
Томашук Дмитро
Соколов Вадим

1. Підготовка тексту

Для аналізу використано текст роману М. Шолохова «Тихий Дон»

Правила попередньої обробки:

1. Усі літери переведено до нижнього регістру.
2. Символи, що не належать до алфавіту (пунктуація, цифри, латиниця), вилучено.
3. Послідовності пробілів зведено до одного пробілу.
4. Сформовано дві вибірки: нормалізований текст із пробілом як символом алфавіту ($m = 33$) та текст із повністю вилученими пробілами ($m = 32$).

2. Розрахунок статистичних характеристик тексту

```
=====
АНАЛІЗ ТЕКСТУ: WITH_SPACES
Загальна довжина: 2729510 символів
=====

Кількість унікальних символів (m): 33
H0 (максимальна ентропія = log2(m)): 5.0444 біт/символ
H1 (ентропія символів): 4.4124 біт/символ

--- ТОП-5 СИМВОЛІВ ---
Символ ' ': 426837 разів | ймовірність p = 0.15638
Символ 'o': 247123 разів | ймовірність p = 0.09054
Символ 'a': 196723 разів | ймовірність p = 0.07207
Символ 'e': 173947 разів | ймовірність p = 0.06373
Символ 'и': 157928 разів | ймовірність p = 0.05786

Біграми З ПЕРЕТИНОМ (крок 1):
Всього біграм: 2729509
Унікальних біграм: 842
H2 (з перетином): 4.0133 біт/символ
--- Топ-5 біграм (з перетином) ---
Біграма ' n': 48829 | p = 0.01789
Біграма 'a ': 47925 | p = 0.01756
Біграма 'и ': 46965 | p = 0.01721
Біграма 'o ': 45554 | p = 0.01669
Біграма ' c': 42576 | p = 0.01560

Біграми БЕЗ ПЕРЕТИНУ (крок 2):
Всього біграм: 1364755
Унікальних біграм: 819
H2 (без перетину): 4.0131 біт/символ
--- Топ-5 біграм (без перетину) ---
Біграма ' n': 24136 | p = 0.01769
Біграма 'a ': 24061 | p = 0.01763
Біграма 'и ': 23722 | p = 0.01738
Біграма 'o ': 22797 | p = 0.01670
Біграма ' c': 21259 | p = 0.01558

=====
АНАЛІЗ ТЕКСТУ: WITHOUT_SPACES
Загальна довжина: 2302673 символів
=====

Кількість унікальних символів (m): 32
H0 (максимальна ентропія = log2(m)): 5.0000 біт/символ
H1 (ентропія символів): 4.4887 біт/символ

--- ТОП-5 СИМВОЛІВ ---
Символ 'o': 247123 разів | ймовірність p = 0.10732
Символ 'a': 196723 разів | ймовірність p = 0.08543
Символ 'e': 173947 разів | ймовірність p = 0.07554
Символ 'и': 157928 разів | ймовірність p = 0.06858
Символ 'н': 141186 разів | ймовірність p = 0.06131

Біграми З ПЕРЕТИНОМ (крок 1):
Всього біграм: 2302672
Унікальних біграм: 911
H2 (з перетином): 4.1774 біт/символ
--- Топ-5 біграм (з перетином) ---
Біграма 'ст': 27605 | p = 0.01199
Біграма 'по': 27447 | p = 0.01192
Біграма 'на': 27173 | p = 0.01180
Біграма 'то': 25583 | p = 0.01111
Біграма 'ов': 25463 | p = 0.01106

Біграми БЕЗ ПЕРЕТИНУ (крок 2):
Всього біграм: 1151336
Унікальних біграм: 894
H2 (без перетину): 4.1774 біт/символ
--- Топ-5 біграм (без перетину) ---
Біграма 'по': 13931 | p = 0.01210
Біграма 'ст': 13704 | p = 0.01190
Біграма 'на': 13674 | p = 0.01188
Біграма 'то': 12730 | p = 0.01106
Біграма 'ов': 12727 | p = 0.01105
```

Аналіз отриманих результатів:

1. Для тексту з пробілами ($m = 33$): $H_0 = 5.0444$ біт/символ, $H_1 = 4.4124$ біт/символ, $H_2 = 4.0133$ біт/символ (як з перетином, так і без). Найчастішим символом є пробіл ($p \approx 0.1564$).
2. Для тексту без пробілів ($m = 32$): $H_0 = 5.0000$ біт/символ, $H_1 = 4.4887$ біт/символ, $H_2 = 4.1774$ біт/символ. Найчастіші літери: «о» ($p \approx 0.1073$), «а» ($p \approx 0.0854$), «е» ($p \approx 0.0755$).
3. Порівняння біграм: результати для біграм із перетином і без перетину виявилися практично ідентичними ($H_2 = 4.1774$) завдяки великому обсягу вибірки (понад 2.3 млн символів). Проте спосіб із перетином використовує у 2 рази більше статистичних даних ($N - 1$ біграм проти $N/2$).

3. Дослідження впливу розподілу символів на ентропію

Очікуваний порядок зростання ентропії: $H(B) < H(A) < H(V)$.

```
=====
РЕЗУЛЬТАТИ ЕКСПЕРИМЕНТУ РОЗДІЛУ 3
Довжина вибірок: N = 100000 символів, Алфавіт: m = 32
=====
Послідовність Б (один символ 'а'):      H1 = 0.0000 біт/символ
Послідовність А (природний текст):      H1 = 4.5122 біт/символ
Послідовність В (випадкова рівномірна): H1 = 4.9998 біт/символ
=====
```

Отримані значення повністю підтвердили теоретичний прогноз: $H_1(B) = 0.0000 < H_1(A) = 4.5122 < H_1(V) = 4.9998$ біт/символ. Будь-яке відхилення розподілу від рівномірного знижує невизначеність і зменшує ентропію джерела.

4. Дослідження залежностей між символами

```
PS D:\PROGRAMS\Microsoft VS Code>
Г (випадкова):      H1 = 1.0000
Г біграми step=1: H2 = 1.0000
Г біграми step=2: H2 = 1.0000
-----
Д (abab...):      H1 = 1.0000
Д біграми step=1: H2 = 0.5000
Д біграми step=2: H2 = 0.0000
PS D:\PROGRAMS\Microsoft VS Code>
```

- Для Г (випадкова): $H_1 = 1.0000$, $H_2 = 1.0000$ (незалежні символи).
- Для Д (періодична «abab...»): $H_1 = 1.0000$, але $H_2 = 0.5000$ (з перетином) та $H_2 = 0.0000$ (без перетину).

Модель біграм дозволяє виявити кореляційні залежності між сусідніми літерами, які повністю ігноруються моделлю окремих символів H_1 .

5. Экспериментальная оценка энтропии джерела

Проведено оцінку умовної ентропії $H^{(10)}$, $H^{(20)}$ та $H^{(30)}$ за методом відгадування наступного символу експериментатором за допомогою програми CoolPinkProgram (виконано понад 50 спроб для кожного контексту).

Лабораторная работа №1

Произвольная часть текста:
ем_я_принишу_им_мои_извинения_этим_людям_я_бы_посоветовал_почитать_какую_ни

Использованные буквы:
я, и, м, а, е, н, ы, ф, ц, й, у, к,

Порядок n-граммы:
5 символов
10 символов
15 символов
20 символов
25 символов
30 символов
35 символов
40 символов
45 символов
50 символов

Введенный символ: o
Символ по счету: 13
Номер эксперимента: 50
Поле ввода символов:
o
Продолжить Другой

Неравенство для энтропии:
2,29848211180034 < H < 2,98062938041322
Двоичная таблица угаданных символов:
00001000000000000000000000000000
10000000000000000000000000000000
00000000000001000000000000000000
00001000000000000000000000000000
0000000000000000000000010000000000

Вероятности:
q[1] = 0,46
q[2] = 0,1
q[3] = 0,04
q[4] = 0
q[5] = 0,06
q[6] = 0,06
q[7] = 0
q[8] = 0
q[9] = 0,02
q[10] = 0
q[11] = 0
q[12] = 0,02
q[13] = 0,04
q[14] = 0,02
q[15] = 0
q[16] = 0,04
q[17] = 0,02
q[18] = 0,02
q[19] = 0
q[20] = 0
q[21] = 0
q[22] = 0,02
q[23] = 0,04
q[24] = 0
q[25] = 0,02
q[26] = 0
q[27] = 0
q[28] = 0
q[29] = 0
q[30] = 0
q[31] = 0,02
q[32] = 0

Строка состояния:
Вы угадали. Для продолжения опыта нажмите "Продолжить", или "Другой" для выбора другого порядка

Лабораторная работа №1

Произвольная часть текста:
й_занял_оставьте_ег

Использованные буквы:

Порядок n-граммы:
5 символов
10 символов
15 символов
20 символов
25 символов
30 символов
35 символов
40 символов
45 символов
50 символов

Введенный символ:
Символ по счету:
Номер эксперимента: 53
Поле ввода символов:
Продолжить Другой

Неравенство для энтропии:
1,99898278531798 < H < 2,79945332878472
Двоичная таблица угаданных символов:
10000000000000000000000000000000
00000000000000000000000000000000
10000000000000000000000000000000
00010000000000000000000000000000
00000000010000000000000000000000

Вероятности:
q[1] = 0,4807692
q[2] = 0,1538461
q[3] = 0,0192307
q[4] = 0,0384615
q[5] = 0,0576923
q[6] = 0,0192307
q[7] = 0
q[8] = 0
q[9] = 0,0384615
q[10] = 0,019230
q[11] = 0,019230
q[12] = 0
q[13] = 0
q[14] = 0
q[15] = 0,019230
q[16] = 0,038461
q[17] = 0,019230
q[18] = 0
q[19] = 0
q[20] = 0,019230
q[21] = 0,019230
q[22] = 0
q[23] = 0
q[24] = 0
q[25] = 0,019230
q[26] = 0
q[27] = 0
q[28] = 0,019230
q[29] = 0
q[30] = 0
q[31] = 0
q[32] = 0

Строка состояния:

Лабораторная работа №1

Произвольная часть текста:
андарты_почти_всегда_он_старается_показать_что_то_что_он_сделал_на_самом_де

Использованные буквы:
я,

Порядок n-граммы:
5 символов
10 символов
15 символов
20 символов
25 символов
30 символов
35 символов
40 символов
45 символов
50 символов

Введенный символ: e
Символ по счету: 2
Номер эксперимента: 52
Поле ввода символов:
e
Продолжить Другой

Неравенство для энтропии:
1,94204924642701 < H < 2,53907002846751
Двоичная таблица угаданных символов:
10000000000000000000000000000000
10000000000000000000000000000000
10000000000000000000000000000000
10000000000000000000000000000000
10000000000000000000000000000000

Вероятности:
q[1] = 0,5576923
q[2] = 0,0769230
q[3] = 0,0576923
q[4] = 0
q[5] = 0,0384615
q[6] = 0
q[7] = 0
q[8] = 0,0192307
q[9] = 0
q[10] = 0
q[11] = 0
q[12] = 0,038461
q[13] = 0,019230
q[14] = 0
q[15] = 0,019230
q[16] = 0
q[17] = 0
q[18] = 0,038461
q[19] = 0,019230
q[20] = 0
q[21] = 0
q[22] = 0,057692
q[23] = 0,019230
q[24] = 0
q[25] = 0
q[26] = 0
q[27] = 0
q[28] = 0,019230
q[29] = 0,019230
q[30] = 0
q[31] = 0
q[32] = 0

Строка состояния:
Вы угадали. Для продолжения опыта нажмите "Продолжить", или "Другой" для выбора другого порядка

Оцінка	Отримане значення
H_1	4.4887 біт/символ
H_2	4.1774 біт/символ
$H^{(10)}$	$2.2985 < H < 2.9806$ (середнє ≈ 2.6396)
$H^{(20)}$	$1.9990 < H < 2.7995$ (середнє ≈ 2.3992)
$H^{(30)}$	$1.9420 < H < 2.5391$ (середнє ≈ 2.2406)

Спостерігається чітка монотонна тенденція до зменшення ентропії при збільшенні врахованого контексту: $H_1(4.4887) > H_2(4.1774) > H^{(10)}(2.6396) > H^{(20)}(2.3992) > H^{(30)}(2.2406)$ біт/символ. Знання довгих залежностей суттєво полегшує вгадування наступних літер тексту, що математично виражається у зниженні умовної ентропії.

Розділ 6. Оцінювання надлишковості джерела

Надлишковість джерела обчислюється за формулою:

$$R = 1 - \frac{H}{H_0}$$

де $H_0 = \log_2(32) = 5.0000$ біт/символ (максимальна можлива ентропія для алфавіту з 32 символів).

Оцінка надлишковості для різних моделей джерела:

- **Модель окремих символів ($H_1 = 4.4887$):**

$$R_1 = 1 - \frac{4.4887}{5.0000} = 0.1023 \quad (10.23\%)$$

- **Модель біграм ($H_2 = 4.1774$):**

$$R_2 = 1 - \frac{4.1774}{5.0000} = 0.1645 \quad (16.45\%)$$

- **Модель умовної ентропії з контекстом 10 символів ($H^{(10)} \approx 2.6396$):**

$$R_{10} = 1 - \frac{2.6396}{5.0000} = 0.4721 \quad (47.21\%)$$

- **Модель умовної ентропії з контекстом 20 символів ($H^{(20)} \approx 2.3992$):**

$$R_{20} = 1 - \frac{2.3992}{5.0000} = 0.5202 \quad (52.02\%)$$

- **Модель умовної ентропії з контекстом 30 символів ($H^{(30)} \approx 2.2406$):**

$$R_{30} = 1 - \frac{2.2406}{5.0000} = 0.5519 \quad (55.19\%)$$

Аналіз результатів

1. Чому природний текст має меншу ентропію на символ, ніж випадкова рівномірна послідовність символів того самого алфавіту?

Відповідь: Максимальна ентропія досягається лише за умови однакової ймовірності всіх літер ($H_0 = 5.0$, у випадковій вибірці $H_1 = 4.9998$). У мові розподіл частот вкрай нерівномірний (літери «о», «а», «е» зустрічаються набагато частіше за «ф» чи «ъ»), що суттєво зменшує невизначеність джерела ($H_1 = 4.4887$).

2. Яку інформацію про джерело враховує H_2 , але не враховує H_1 ?

Відповідь: H_1 сприймає символи як повністю ізольовані події. H_2 враховує статистичний зв'язок між парами сусідніх символів (умовну ймовірність появи однієї літери після іншої).

3. Чи можуть два тексти мати однакове H_1 , але різне H_2 ? Наведіть приклад із виконаних експериментів.

Відповідь: Так. У Розділі 4 послідовності Г і Д мали однакові частоти літер $p = 0.5$ ($H_1 = 1.0000$ для обох), проте у випадковій Г значення $H_2 = 1.0000$, а в періодичній структурі Д значення впало до $H_2 = 0.5000$ (і до 0.0000 без перетину).

4. Як вилучення пробілів вплинуло на отримані значення ентропії? Поясніть отриманий результат.

Відповідь: Вилучення пробілу підвищило ентропію H_1 з 4.4124 до 4.4887. Пробіл був найбільш частим символом тексту ($p \approx 0.156$). Його усунення зробило розподіл частот літер, що залишилися, більш рівномірним.

5. Чому оцінки H_2 , отримані за біграмами, що перетинаються та не перетинаються, можуть дещо відрізнятися?

Відповідь: Біграми з перетином дають вибірку вдвічі більшого розміру ($N - 1$ пар проти $N/2$). Обчислення без перетину залежить від точки відліку (зсуву на 1 символ), що для коротких текстів може збігатися з морфологічними патернами мови (префікси, закінчення).

6. Чому значення $H_1, H_2, H^{(10)}, H^{(20)}$ та $H^{(30)}$ відрізняються?

Відповідь: Додавання відомого контексту завжди зменшує або залишає незмінною невизначеність: $H(X|Y) \leq H(X)$. Чим більше символів передісторії відомо, тим точніше передбачається наступна літера.

7. Який із проведених експериментів найкраще демонструє наявність залежностей між послідовними символами?

Відповідь: Експеримент розділу 4 з періодичною послідовністю Д (падіння H_2 до 0) та експеримент у CoolPinkProgram, де контекст у 30 символів знижив ентропію з 4.49 до 2.24 біт/символ.

8. Як отримані результати пов'язані з можливістю стиснення природного тексту без втрати інформації?

Відповідь: Ентропія H_∞ визначає теоретичну межу стиснення тексту без втрат. Оскільки надлишковість мови перевищує 55%, а ентропія на символ падає до ≈ 2.2 біт проти 8 біт стандартного байта, текст гарантовано можна стискати архіваторами у 3–4 рази.

Висновки

1. Вивчено та експериментально порівняно різні моделі джерела відкритого тексту для оцінки його ентропії та надлишковості.
2. Для тексту роману «Тихий Дон» без пробілів отримано оцінки: $H_1 = 4.4887$ біт/символ, $H_2 = 4.1774$ біт/символ.
3. Доведено, що врахування контексту в мові суттєво знижує невизначеність: умовна ентропія для 30-грам спадає до $H^{(30)} \approx 2.2406$ біт/символ.

4. Розрахована надлишковість джерела складає понад 55%, що обумовлює високий рівень стиснення тексту статистичними та словниковими алгоритмами.